

VINUNIVERSITY

GPU FinOps & Cost Optimization

AICB-P2T2 · Ngày 25 · Chương 5: Vận Hành

Giảng viên

VinUniversity · Phase 2 · Track 2 · Tuần 5

HÃY SUY NGHĨ...

"Bạn đang tiêu bao nhiêu cho GPU mỗi ngày? Và bao nhiêu % là lãng phí?

Case study (giá 2026): *4×H100 idle 12h/đêm @ neocloud $2.50/hr = $120/ngày =* ***$43,800/năm****; cùng node trên hyper-scaler ($7.44/hr) = $357/ngày =* ***$130k/năm****.*

Hôm nay: cắt 40–95% chi phí GPU bằng unit economics ($/1M-token), purchasing strategy, MFU/MBU, và FinOps governance — rồi close Chương 5 với Quiz + Milestone 2."

Giữ câu hỏi này trong đầu khi học bài hôm nay.

Nội Dung Bài Học

1. GPU Cloud Cost Anatomy
2. Bức Tranh GPU & Giá 2026
3. Neoclouds vs Hyperscalers
4. Purchasing & Commitment Strategy
5. Utilization Efficiency: MFU/MBU/Roofline
6. Right-Sizing, Fractional GPU & Autoscaling
7. Inference Cost Levers
8. Disaggregated Serving & KV-cache
9. FinOps Framework, FOCUS & Unit Economics
10. Cost Observability & Allocation
11. Power & Sustainability Economics
12. Demo & Lab 25
13. Tổng Kết Chương 5 + **Quiz + Milestone 2**

Mục Tiêu

Sau buổi học này, bạn sẽ:

1. Re-baseline chi phí GPU theo giá 2026 (Blackwell/H200/MI300X) và đo bằng **$/1M-token**, không phải $/GPU-hr
2. Chọn purchasing strategy đúng (spot / on-demand / Capacity Block / reserved) bằng **break-even utilization**
3. Phân biệt GPU-Util% (đánh lừa) với **MFU / MBU / goodput** — thước đo hiệu quả chi phí thật
4. Áp discount stack (batch $-50\% \times$ caching $-90\% \approx 95\%$), disaggregation, fractional GPU
5. Thiết kế FinOps governance: FOCUS, unit economics KPI, showback $\rightarrow$ chargeback

> Cost anatomy $\rightarrow$ Giá 2026 $\rightarrow$ Neocloud $\rightarrow$ Purchasing $\rightarrow$ MFU/MBU $\rightarrow$ Fractional GPU $\rightarrow$ Inference levers $\rightarrow$ Disaggregation $\rightarrow$ FinOps/FOCUS $\rightarrow$ Observability $\rightarrow$ Power $\rightarrow$ Quiz + Milestone 2

Deliverable Cuối Ngày

VINUNIVERSITY

> Cost optimization plan + projected savings ($/1M-token before/after) + Quiz + Milestone 2 platform demo

- Cost baseline report: GPU utilization (MFU/MBU), idle time, wasted spend hiện tại
- Optimization plan: purchasing + right-sizing + batching/caching — projected savings có số liệu
- **Quiz Chương 5:** 15 câu CI/CD, LLMOps, Monitoring, Governance, FinOps
- **Milestone 2:** Demo operations platform end-to-end

Chi Phí GPU Cloud: Breakdown 2026



- **Power = line-item tăng nhanh nhất:** H100 node ∼1,400 W/GPU all-in; power ∼10–20% TCO nhưng ∼30–40% *opex* (xem §11)
- **Hidden costs:** egress $0.09/GB (AWS), NAT gateway $0.045/GB, Secrets Manager $0.40/secret/tháng, inter-AZ traffic
- **Đơn vị đo đúng không phải $/GPU-hr** mà là **$/1M-token** (inference) / **$/job** (training) — xem §2 & §5

Lãng Phí & FinOps Maturity

1. GPU idle qua đêm — training xong, instance vẫn chạy
2. Over-provisioned: H100 cho inference 8B (A10G/L4 đủ)
3. Unused reserved capacity mua 1 năm, workload đổi
4. Dev environments chạy 24/7 (chỉ cần giờ hành chính)
5. Cao điểm GPU-Util% nhưng MFU thấp — trả tiền cho FLOPS không dùng (§5)

- Vòng đời **Inform** → **Optimize** → **Operate**
- Hầu hết AI teams mới ở **Inform** — audit *trước* khi optimize
- Framework đầy đủ (Scopes “Cloud+”, FOCUS, maturity, KPI) ở **§9**

Rule of thumb: GPU utilization <30% (hay MFU thấp) = cần right-size ngay.

Cú Sụp Giá H100 — và Bẫy "Năm Nào Cũng Rẻ Hơn"

- Đỉnh ∼**$8/GPU-hr** (2023) → ∼**$2/hr** neocloud (cuối 2025): giảm **64–75%**
- 2026 **đảo chiều**: hợp đồng 1-năm bật lại **+40%** ($1.70→$2.35/hr, 10/2025→3/2026)
- On-demand Hopper "sold out"; hyperscaler on-demand lên ∼$7.44/hr

- H100 SXM ∼**$50k** trọn đời 5 năm
- Cho thuê <**$1.65/hr** → **lỗ**
- >**$2.85/hr** → **thắng cả thị trường chứng khoán**

Re-baseline mọi TCO về giá 2026 (số A100/A10G 2023 *thổi phồng chi phí 3–4*×).
Thị trường đang **siết lại** → khóa reserved sớm, đừng đặt cược "chờ rẻ hơn".

$/GPU-hr Là "Vanity Metric" — Ngân Sách Theo $/1M-token

Chip / config	$/GPU-hr	$/1M-token	Bài học
H100 (cùng chip, đa cloud)	$1.49–$6.98	—	4–5× chênh → **provider arbitrage**
GB300 NVL72 vs Hopper	cao hơn	**35× rẻ hơn/token**	50× throughput/MW
B300 vs B200 (Llama-70B FP4)	+23%	−**26%** ($0.055 vs $0.074)	mới = rẻ hơn/token
MI300X (decode mem-bound)	$1.85–2.5	—	−**55% $/GB-VRAM** vs H100

Quy tắc: chuẩn hóa về **$/1M-token** (inference) hoặc **$/job** (training). $/hr cao *không* nghĩa đắt hơn/token — GB300 đắt/giờ nhưng rẻ nhất/token.

Thực Đơn Silicon 2026: Chọn Chip Theo Workload

Vendor / chip	$/chip-hr (neocloud)	Mạnh nhất cho	Lock-in
NVIDIA H100 / H200	$1.5–7 / mainstream ∼$2.5	sàn Hopper / inference 141GB	thấp (portable)
NVIDIA B200 / B300	$4–6 / $3.29 spot	**biên giới rẻ nhất/token**	thấp
AMD MI300X / MI355X	$1.85–2.5 / 288GB	70B single-GPU, $/GB-VRAM	trung (ROCm)
AWS Trainium2/3	∼30–60% rẻ hơn	training giá-perf	**cao (AWS)**
Google TPU v6e/v7	∼$4.2–4.5	batch JAX captive	**cao (GCP)**

Quyết định: NVIDIA = portable + spot arbitrage đa-cloud; AMD = đòn bẩy đàm phán + $/GB-VRAM; Trainium/TPU = rẻ 30–60%/đơn vị nhưng *captive* một cloud. **Đòi $/1M-token benchmark trên workload của bạn trước khi cam kết custom silicon** (vendor tok/$ claims dùng FP4 + model chọn lọc).

Neocloud vs Hyperscaler 2026: Khoảng Cách Giá, Làm Mới

- Hyperscaler ∼**$7.44/GPU-hr** vs neocloud ∼**$2.5/hr = ∼3× / 67% rẻ hơn**
- Đuôi rẻ: AWS $6.88 vs RunPod ∼$2.39 / Lambda ∼$2.49 vs spot floor $1.03 = tới ∼85% rẻ hơn

Lưu ý: Frontier *đảo ngược*: B200 neocloud ∼$5.09/GPU-hr, **+24% Q1 2026**, volatility 11.4% (vs 0.5% H100 hyperscaler) — thị trường mỏng, tăng, biến động.

Cập nhật quy tắc: "40–70% rẻ hơn" (A100-era) → nay là ∼**3× mainstream**, 3–6× silicon mới. **Một chính sách mua không hợp mọi thế hệ.**

Stack Neocloud: Từ $/GPU-giờ Đến $/1M-token (và Giá Của Discount)

- **Bare-metal/reserved** ($/GPU-hr)
- **Per-second serverless** scale-to-zero (Modal H100 ∼$3.95/active-hr)
- **Per-token API** (Together $0.03–$4.50/1M; Llama 3.3 70B $1.04/$1.04)
- Chọn theo duty cycle: spiky → scale-to-zero; ổn định → reserved; util thấp → *mua token, không mua GPU*

Lưu ý: **Cái giá (governance):** SLA 99.99% vẫn = ∼52 phút/năm down-time; managed services mỏng; rủi ro đối tác thật (một neocloud ∼$8.7B nợ, ∼$7.5B đáo hạn 2026). **FinOps phải định giá exit/migration + khả năng thanh toán của nhà cung cấp.**

Vì sao rẻ: năng lượng rẻ + **nợ GPU-backed** (CoreWeave $8.5B @ ∼5.9%) = arbitrage chi phí vốn.

Buy vs Rent vs Reserve — Khi Nguồn Cung GPU Đã Nới Lỏng

- **Buy:** ∼$25k–30k/H100 (PCIe); break-even thô ∼8,300 GPU-hr; all-in (điện/làm mát/khấu hao/ops) ∼**16–18+ tháng** ở ∼100% utilization
- **Rent on-demand:** rẻ nhất trừ khi utilization cao bền vững; AWS cắt EC2 GPU on-demand tới **44–45%** (hiệu lực 1/6/2025)
- **...nhưng 1/2026 AWS tăng Capacity Blocks ∼15%** (p5e.48xlarge $34.61→$39.80/hr) — **scarcity premium** cho capacity đảm bảo
- **Reserve (neocloud blocks):** con đường giữa — giá dưới on-demand, không capex; tốt cho workload ổn định 12 tháng+

Cú cắt on-demand (−45%) và cú tăng Capacity Block (+15%) cách nhau ∼7 tháng — **giá là tín hiệu cung-cầu thời gian thực**, không phải xu hướng một chiều.

Thang Cam Kết 2026: Spot / On-Demand / Capacity Block / Reserved

VINUNIVERSITY

Tầng	Discount	Cam kết	Dùng khi
Spot / Preemptible	-40–70% (GCP tới -80%)	không, thu hồi	job chịu gián đoạn + checkpoint
On-Demand / Serverless	0% (base)	không	tải spiky, util $<$5–6h/ngày
Capacity Block (AWS)	vừa	1–182 ngày, đặt $\leq$8 tuần	burst đảm bảo, giá cố định
DWS Flex-start (GCP)	-53%	$\leq$7 ngày	batch/training ngắn
Reserved / CUD 1–3yr	$\sim$45–55% (GPU)	1–3 năm	workload ổn định, util cao

break-even utilization $\approx$ **1** $-$ **discount%**. Discount 45% $\rightarrow$ cần $\sim$55% util ($\sim$13.2h/ngày) để reserved có lời. Reserved chạy 70% util *vẫn phí* $\sim$*30%* — gắn quyết định mua vào util **đo được**.

Spot Instances: Interruption Giờ Theo Từng Chip

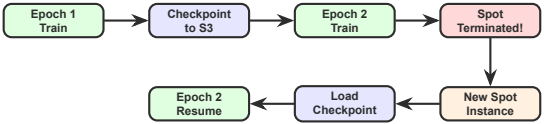
VINUNIVERSITY

- AWS Spot: −40–70%, notice ∼**2 phút**
- GCP Spot/Preemptible: tới −80%, notice ∼**30 giây**
- Spot Fleet: request đa AZ/instance type để giảm gián đoạn

- H100: $<$**5%**
- A100: **15–20%**
- V100 / RTX PRO 6000: $>$**20%**
- $\Rightarrow$ chip mới = spot *an toàn hơn*

Mixed fleet: 20% on-demand (baseline) + 80% spot (burst) — cân bằng cost vs reliability.

Checkpoint Strategy cho Spot Training



- Save state mỗi epoch (hoặc mỗi 30 phút cho long epochs); lưu S3/GCS → resume bất kỳ instance nào
- PyTorch Lightning `ModelCheckpoint` / async checkpointing tự động hoá
- Best practice: test resume flow **trước** khi chạy long training

Discount Ladder & Multi-cloud Spot Arbitrage

- Managed Spot: ∼**3**× (GPU train) đến **6.5**× (CPU batch) rẻ hơn — auto-recover preemption + route GPU rẻ nhất
- SkyServe: serve ∼**50%** rẻ hơn cross-cloud
- `sky launch task.yaml` chọn provider tối ưu

- AWS H100 3yr: ∼**45%** (headline 72% là thời CPU)
- Azure ND H100 v5 3yr: ∼**55%**
- Neocloud blocks: tới **60%**
- GCP: **accelerator bị loại** khỏi flexible CUD

Lưu ý: Bẫy FinOps: **đừng** áp % CUD toàn-cloud cho GPU — model theo SKU thực trước khi cam kết.

Blackwell Khan Hiếm: Khóa Capacity Sớm

- B200/GB200 bán hết tới giữa 2026, backlog ∼3.6 triệu chip
- AWS Capacity Blocks **+∼20%** (1/7/2026): B300 $11.70→$14.04, B200 $10.30→$12.36/acc-hr
- Reserved Blackwell đang **đắt lên**, không rẻ đi

- **Blackwell** (khan): *đảm bảo sớm* bằng commitment / Capacity Block
- **H100/A100** (đã nới lỏng, xem §2): giữ *linh hoạt* spot / on-demand
- Giá GPU mang tính **chu kỳ** — theo cung-cầu thực, đừng đặt cược một chiều

Một chính sách mua *không* hợp mọi thế hệ: khan → commit; dư → spot. Gắn mọi cam kết vào **break-even utilization** (§4).

GPU-Util% Nói Dối: nvidia-smi 100% $\neq$ Hiệu Quả Chi Phí

VINUNIVERSITY

Lưu ý: **nvidia-smi "GPU-Util" =** % thời gian có $\geq$1 kernel chạy. KHÔNG đo dung lượng tính toán — **1 thread trên 1 SM đã báo 100%**.

- **MFU** cho training (compute-bound)
- **MBU** cho decode (memory-bound)
- Lấy từ **DCGM**: SM activity, Tensor Core %, HBM BW — không phải GPU-Util

- Training báo 100% GPU-Util nhưng **MFU thực chỉ $\sim$20–30%**
- $\Rightarrow$ trả full GPU-hour cho $< \frac{1}{2}$ FLOPS thực dùng

FinOps: đừng capacity-plan / mua thêm GPU dựa trên GPU-Util — đó là đồng hồ "đang bận", không phải "đang hiệu quả".

MFU, MBU & Roofline: Hai Thước Đo Chi Phí Thật

- = achieved FLOPs / peak FLOPs (từ PaLM)
- Tốt **35–45%**, xuất sắc **50%+**; Llama-3 405B ∼38–43%
- 70B config mặc định $<$30% $\rightarrow$ sửa TP 8$\rightarrow$1 + selective checkpointing = ∼**2**$\times$ **MFU =** ∼**2**$\times$ **rẻ hơn**

- MBU = achieved BW / peak BW; target ∼**60%** (H100-80GB batch-1)
- Ridge H100 ∼295 FLOP/byte (BF16); decode batch-1 chỉ **1–2 FLOP/byte** $\rightarrow$ memory-bound
- Decode scale theo HBM BW: H100 3.35 $\rightarrow$ H200 4.8 $\rightarrow$ B200 **8 TB/s**

Hệ quả mua sắm: cho decode, trả tiền cho **$/TB-bandwidth**, không phải $/TFLOP (H200 ∼1.9$\times$ inference vs H100 nhờ BW).

Goodput & Cost-per-Token: Thước Đo FinOps Cuối Cùng

- Goodput = req/s **đạt SLO** (TTFT + TPOT)
- 10 req/s nhưng 3 đạt SLO → goodput = 3 (7 req đã trả tiền nhưng vô dụng)
- Tối ưu goodput = cắt fleet GPU (disaggregation tới ∼2× req/GPU — chi tiết §8)

- Blackwell DeepSeek-R1: ∼6,000 tok/s/GPU, **$0.12/1M** = ∼35× rẻ hơn Hopper
- Đòn bẩy lớn nhất là **utilization**: GPU ở 10% tải → **10× cost/token**
- Thuê GPU thô chỉ là 25–35% TCO self-host

Right-Sizing: GPU-Util Là Khởi Đầu, Không Phải Đích

Workload	GPU-Util (time-active)	Target	Action nếu thấp
Inference (single model)	20–40%	>60%	Multi-model serving, MIG, fractioning
Inference (batched)	50–70%	>75%	Tune batch size, continuous batching
Fine-tuning	60–80%	>80%	Larger batch, gradient accum
Pre-training	80–95%	>90%	Optimise data loading

Lưu ý: Cột trên là *GPU-Util (time-active)* — chỉ báo "đang bận". Hiệu quả chi phí thật đo bằng **MFU/MBU** (§5). Nguồn util: `nvidia-smi dmon` / DCGM Exporter → Prometheus → Grafana.

Serverless GPU & Scale-to-Zero: Trả Tiền Theo Giây

- Modal H100 ∼$3.95/hr, B200 ∼$6.25/hr
- RunPod Flex H100 PRO ∼$4.18/hr
- Baseten (per-minute) H100 ∼$6.50/hr
- Flex (scale-to-zero) vs Active (24/7, −20–32% khi uptime cao)

Lưu ý: Cold start = paid dead time: 20–60s init+model-load tính full rate. “Model Parking Tax”: keep-warm +26–66 W/GPU (>98% idle power).

Break-even ∼30% duty cycle: tải spiky → serverless; tải ổn định cao → reserved (serverless premium ∼1.3–3× bare-metal).

Fractional GPU: Một Card, Nhiều Tenant — Cắt $/User

- **MIG** (A100/H100): phân vùng phần cứng, memory riêng, isolation cao
- **Time-slicing / MPS**: mật độ cao hơn, isolation thấp hơn
- Đánh đổi: **cost density** $\leftrightarrow$ **isolation**

- **Hiệu quả compute** (MFU) doanh nghiệp thường chỉ $\sim$**5%**, dù GPU-Util time-active 60–70%
- Run:ai: **0.5 GPU = 77% throughput, 86% user capacity**; co-location $\rightarrow$ tới **3**$\times$ **users**
- **KAI Scheduler** open-source (Apache 2.0, 4/2025) — bỏ phí license
- **DRA GA** K8s 1.34 (8/2025): cấp "GPU $\geq$X GB" native

Kubernetes Cost-Autoscaling Stack 2026: Zero Idle GPU

- **Karpenter** — consolidation + bin-packing: gom pod vào ít node nhất, xóa node rỗng; spot GPU → giảm ∼40–60% vs Cluster Autoscaler
- **KEDA** — scale-to-zero: GPU inference pods → 0 replica khi util = 0 qua cooldown
- **Kueue** — gang scheduling + quota theo team + cohort borrowing → chống GPU hoarding
- **DRA + KAI Scheduler** — nền fractioning native + fair-share/over-quota

Tấn công **cả 2 lớp lãng phí**: idle *trong-card* (fractioning §trên) + idle *nguyên-node* (autoscaling/spot). Hai lớp này nhân nhau.

LLMflation: Giá Token Rơi $\sim$10$\times$/năm — Nhưng Không Đều

- Cùng năng lực: inference giảm $\sim$**10$\times$/năm**
- GPT-3-level \$60/1M (2021) $\rightarrow$ \$0.06/1M (Llama 3.2 3B, 2024) = **1,000$\times$ trong 3 năm**
- "Ngang GPT-4" ra mắt \$30/\$60/1M (3/2023) nay $<$**\$1/1M**

Lưu ý: **KHÔNG đều** (Epoch AI): biên độ **9$\times$–900$\times$/năm**, trung vị $\sim$50$\times$ $\rightarrow$ tách dự báo theo *tầng năng lực*.

Frontier 6/2026: GPT-5.5 \$5/\$30 · Opus 4.8 \$5/\$25 · Gemini 3.1 Pro \$2/\$12 (gấp đôi khi prompt $>$200K).

Cú Sốc DeepSeek: Kiến Trúc LÀ Đòn Bẩy Chi Phí

Lưu ý: Headline **$5.576M** chỉ là GPU pre-training ($\sim$2,048 H800 $\times$ 55 ngày). KHÔNG gồm CapEx/R&D. Thực tế (SemiAnalysis): $\sim$**$1.6B CapEx + $944M opex**, $\sim$50k GPU $\rightarrow$ chênh $\sim 100\times$.

Bài học: luôn đòi **full TCO**, không tin headline.

- **MLA** (Multi-head Latent Attention): -93.3% KV-cache
- **MoE**: chỉ kích hoạt 37B/671B params/token
- **FP8**: $/token rẻ
- API: R1 \$0.55/\$2.19 vs o1 \$15/\$60 = $\sim$**27$\times$ rẻ hơn**
- Thị trường: Nvidia mất $\sim$\$600B vốn hóa 1 ngày (27/1/2025)

Reasoning = Bom Chi Phí Mỗi Truy Vấn

Lưu ý: Test-time compute nổ chi phí *mỗi* truy vấn: "thuế reasoning" **+5–10**$\times$ token bị tính; thinking-token ẩn tính giá *output* ($\sim$10k token suy luận cho 1 câu 500 token = $\times$**21**).

- **21.8%** cặp model *đảo giá* (tới 28$\times$): rẻ trên giấy, đắt khi chạy
- Tin tốt: reasoning giảm nhanh — o4-mini-low $\sim$\$0.05/task
- $\Rightarrow$ benchmark **\$/task thực**, chiến lược "chờ & định giá lại"

Discount Stack: Batch -50% $\times$ Caching -90% $\approx$ 95% Off

Lever	Giảm	Điều kiện
Batch API	$-$**50%**	SLA 24h; latency-tolerant (eval, enrich, nightly)
Prompt caching (read)	$-$**90%** ($0.1\times$)	Anthropic; write $1.25\times/2\times$, cần $\geq$2 reads
OpenAI / Gemini cache	-50 đến -90%	Gemini có *phí lưu* \$1–4.5/1M-tok-giờ
Batch $\times$ Caching (stack)	$\approx$**95% off**	multiplier nhân được (Anthropic xác nhận)

Lưu ý: Caveat: caching chỉ lời trên ngưỡng read; phí lưu Gemini có thể lật ngược phép tính $\rightarrow$ **cache có chủ đích**, đừng cache mù.

Tầng Small-Model: Batching · Caching · Cascading · Quantization

- Request batching: throughput $\sim 8\times$, cost/req $\downarrow$ (vLLM continuous batching)
- Redis/semantic cache: hit 30–40% (chatbot)
- Model cascading: 8B xử lý 80%, escalate 20% — FrugalGPT tới **98%**, RouteLLM 85%+
- Quantization: FP8/FP4 (Blackwell) là frontier; AWQ 4-bit là tầng INT4

Mode	Tok/s	$/M tok
FP16 (A10G)	1200	$0.83
AWQ 4-bit	1800	$0.55
Savings		**34%**

Stacked: batching+caching+cascading+quant $\rightarrow$ 70–85% vs naive.

Disaggregation: Tách Prefill/Decode = 7–30× QPS Cùng GPU

- **Ý tưởng:** prefill compute-bound, decode memory-bound — chạy chung lãng phí cả hai → tách pool, right-size mỗi pool theo SKU rẻ nhất
- **DistServe** (OSDI'24): **7.4× request** / SLO chặt 12.6× (>90% req đạt SLO)
- **Mooncake** (Kimi, FAST'25): **+75% req thực**, tận dụng CPU/DRAM/SSD nhàn rỗi làm KV tier
- **NVIDIA Dynamo**: tới **30× request** (DeepSeek-R1 671B, GB200 NVL72); >2× Llama-70B Hopper; Qwen3-235B-FP8 1.86×

Lưu ý: KV-transfer tăng theo độ dài context → thắng ở **QPS cao + context dài chia sẻ**; deployment nhỏ có thể *lỗ*.

KV-cache Là Tiền: cache-hit% Thay "Số Token" Làm KPI

- Anthropic read 0.1× (∼90% off); OpenAI 50→90%
- DeepSeek hit ∼1/10 (V4 Flash ∼98%)
- Chênh **50–100**× giữa hit/miss

- KV offload/tiering cho vLLM: −**69% chi phí prefill** @80% hit (4×H100, prompt 128K), throughput tới 15×
- **GA 1/2026**; dùng bởi GKE Inference, CoreWeave, Cohere

Cấu trúc prompt để prefix tĩnh (system prompt, RAG context, few-shot) ổn định cache; **theo dõi cache-hit% như chỉ số chi phí chính**.

Mỗi “Tối Ưu” Có Vùng Chi Phí Riêng — Đo $/token Trước/Sau

- **Speculative decoding**: -48% \$/1M token khi *latency-bound* NHƯNG **+19% khi throughput bão hòa**; ROI gắn acceptance rate ($\geq 60\%$; EAGLE-3 $\sim 2.5\times$ trên vLLM)
- **Chunked prefill**: bảo vệ ITL (inter-token latency) nhưng chunk 512 thêm tới **+25% overhead**; chunk ~ 2048 gần như 0
- **NVIDIA NIM**: chi phí *theo GPU* (AI Enterprise $\sim$\$4,500/GPU/năm $\approx$ \$1/GPU-hr) + tiền thuê GPU $\rightarrow$ chỉ lời trên ngưỡng break-even utilization

Lưu ý: Quy tắc: mỗi lever có *chế độ tải* phù hợp — **đo unit economics trước và sau**, đừng giả định “nhanh hơn = rẻ hơn”.

FinOps 2025: Từ Cloud Sang “Cloud+”, AI Là Một Scope

- Thêm **Scopes**: Public Cloud · SaaS · Data Center · **AI** · Licensing · Private Cloud
- Vòng đời **Inform** → **Optimize** → **Operate** giữ nguyên
- Cloud+ thực tế: SaaS 90%, licensing 64%, private cloud 57%

- **98%** đội quản chi phí AI (so 31% hai năm trước)
- “AI value management” = kỹ năng cần #1
- Lãng phí cloud lên **29%** (Flexera 2026) — lần tăng đầu sau 5 năm, do AI làm forecast khó

Why now: đó là lý do GPU FinOps tồn tại — AI biến chi phí thành biến số khó dự báo nhất.

AI Unit Economics: $/Token · $/Inference · $/Outcome

KPI	Công thức (FinOps for AI)	Ví dụ
Cost / Token	Total $ / Tokens	$2,500 / 1M = **$0.0025**
Cost / Inference	Total $ / #inferences	$5,000 / 100k = **$0.05**
Utilization	Actual / Provisioned	800/1000 = **80%**
ROI	(Benefit−Cost)/Cost	**150%**
Token yield rate	% token tạo hành động KD	nối token → value

"Một token rẻ đi, nhưng *tổng* token thì không." Chi GenAI doanh nghiệp **$1.7B (2023)** → **$37B (2025)**. Tối ưu **token yield** (token tạo ra giá trị KD), đừng chỉ tối thiểu hóa token; structured-output cắt 30–60% token (model routing/cascading ở §7).

FOCUS: Chuẩn Hóa Dữ Liệu Chi Phí Đa Nhà Cung Cấp

- **FOCUS** (FinOps Open Cost & Usage Spec) — chuẩn mở normalize billing đa cloud về một schema
- **1.2** (5/2025) thêm cột virtual-currency/token · **1.3** (12/2025) Contract Commitment + Split Cost Allocation · **1.4** (6/2026) 47 cột
- Native export từ $>$**12 nhà cung cấp**: AWS, Azure, GCP, Oracle, Alibaba, Nebius, Databricks…
- Nghề hóa: chứng chỉ **FinOps Certified for AI** (ra mắt 6/2025, thi từ 3/2026); maturity Crawl/Walk/Run

Lưu ý: AI token consumption *đầy đủ* (model identity, input/output tokens) scoped cho **FOCUS 1.5 — CHƯA ratified** (6/2026).

Hai Tầng Quan Sát Chi Phí AI: $/GPU-giờ + $/1M-token

VINUNIVERSITY

- **DCGM → Prometheus → Kubecost 3.0 / OpenCost**
- Chi phí GPU theo pod/namespace, phân bổ theo *mức sử dụng*
- Tách **Workload Idle vs Infrastructure Idle**

- **LiteLLM** proxy (100+ provider) + Langfuse/Helicone
- $/request, $/1M-token theo API-key/team
- Budget cứng chặn request vượt hạn mức

Hợp nhất: FOCUS đưa token vào cùng schema với cloud (AI-token đầy đủ đợi FOCUS 1.5).

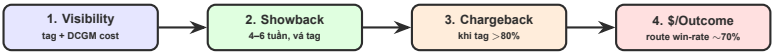
Tagging, Quota & Per-Service Cost Breakdown

- `team=ml-platform` · `project=rag-service`
- `env=production` · `cost-center=engineering`
- Enforce tags bằng SCP/OPA policies
- K8s label → DCGM → Prometheus

- K8s `ResourceQuota` per namespace
- Team budget: max 4 GPUs, 100GB storage
- **Kubecost 3.0** (GA 9/2025): ClickHouse, bỏ Prometheus dep, **GPU-aware (DCGM)**, free $<$\$1M
- "RAG \$45/day, Embedding \$12/day"

Lưu ý: Cloud-native gotcha: split GPU/accelerator cost của EKS ở **CUR 2.0 SCAD / Data Exports**, KHÔNG ở Cost Explorer UI (EKS-only, 9/2025).

Từ Showback Đến Chargeback Trên Cụm GPU Dùng Chung



- Mô hình phân bổ: per-namespace / per-tenant / per-token / per-experiment
- Chạy **showback 4–6 tuần** vá lỗ hổng tag → chuyển **chargeback khi tag-coverage >80%**
- Util GPU AI TB chỉ ~60–70%, kiểm toán xấu nhất ~5% — lõi bài toán lãng phí

Bức Tranh Công Cụ & Cảnh Báo: Token Bill Chỉ Là 1/9

- IBM mua Apptio + Kubecost → Cloudability/Turbonomic/Kubecost
- FOCUS-based: Vantage, CloudZero, Finout, nOps
- LLM token: LiteLLM, Langfuse (Helicone → maintenance mode 2026)

Lưu ý: (FinOps X 2026) token bill chỉ là **1 trong 9 khoản** chi. 8 khoản còn lại — retrieval, orchestration, KV-cache infra, eval, governance, nhân lực, lãng phí/lỗi, tích hợp — thường *không* được đo.

Thang trưởng thành: visibility → cost/token → **cost per verified outcome**.

Power, Không Phải GPU, Là Nút Thắt

- Giá capacity lưới PJM tăng $\sim$**11**$\times$ trong 2 năm ($28.92 $\rightarrow$ $329.17/MW-day); data center chịu **63%** khoản tăng
- Một site AI cần **100–750 MW**; đấu nối lưới mới mất **24–36 tháng** (4–7 năm ở hub nghẽn) — *capacity*, không phải chip, giới hạn tăng trưởng
- **$/MW là đơn vị mới**: $\sim$$10M/MW (vỏ) $\rightarrow$ $20–30M/MW (AI-optimized) $\rightarrow$ $\sim$$30–44M/MW all-in
- Power $\sim$10–20% TCO nhưng $\sim$**30–40% opex**

Đặt training/batch latency-tolerant nơi điện rẻ **và** sạch: $\sim$5–6¢ (E. Washington) vs $\sim$15¢/kWh (CA); carbon $\sim$6 vs $\sim$660 gCO_2/kWh (Norway vs Poland, $>$100$\times$).

Tokens-per-Watt: Năng Lượng/Truy Vấn Là Unit Economics

- **0.24 Wh**, 0.03 gCO_2e, 0.26 mL nước
- Giảm **33**× **energy / 44**× **carbon** trong 12 tháng
- Chỉ **58%** năng lượng là TPU; bạn trả cho ∼42% non-accelerator

Lưu ý: Reasoning tốn **74–86**× năng lượng/truy vấn: o3 ∼39.2 Wh, DeepSeek-R1 ∼33.6 Wh vs GPT-4.1 nano ∼0.45 Wh.

Đòn bẩy: model routing + reasoning-token budget cắt năng lượng (và $) 1–2 bậc; theo dõi **Wh/query** như $/1M-token.

Carbon & Nước Như Đòn Bẩy Chi Phí Có Quản Trị

- **PUE** chạm sàn: Google fleet **1.09** vs industry $\sim$1.56 ($\rightarrow$ cơ sở trung bình đốt thêm $\sim$56% điện cho overhead trên mỗi watt IT)
- Chuẩn hóa: **SCI là ISO/IEC 21031:2024** (carbon/inference) — đối ứng carbon của $/1M-token cho dashboard & ESG
- **Carbon-aware scheduling** job hoãn được: cắt carbon $\sim$**20–50%** *và* thường trúng điện off-peak rẻ hơn
- Hyperscaler hedge điện: PPA hạt nhân 20 năm (MSFT 835 MW Three Mile Island $\sim$2028; Google 500 MW SMR; Amazon 320 MW + $>$5 GW)

Sustainable AI không chỉ "nice-to-have": region + model selection + scheduling = **cost savings + carbon reduction cùng lúc**.

Live Demo: GPU Cost Audit & Optimization 2026

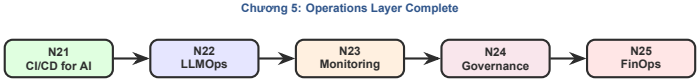
1. **Bước 1 — Audit hiệu quả:** `nvidia-smi dmon` + DCGM → đo **MFU/MBU** (không chỉ GPU-Util%), phát hiện idle
2. **Bước 2 — Discount stack:** bật request batching + prompt caching, benchmark **$/1M-token** trước/sau
3. **Bước 3 — Allocation:** cài Kubecost 3.0 + LiteLLM, tag resources, xem per-service $/GPU-hr *và* $/token; export FOCUS
4. **Bước 4 — Purchasing:** tính **break-even utilization**; viết checkpoint/resume cho training job trên spot
5. **Bước 5 — Report:** cost optimization report: baseline vs optimized, projected savings ($/1M-token + $/job)

Mục tiêu: GPU FinOps Optimization Workshop

Deliverable: Cost optimization report (baseline vs optimized, $/1M-token) + Milestone 2 platform demo

Thời gian: 2.5h

Recap Chương 5: Vận Hành



- **Re-baseline:** giá GPU 2026 (Blackwell/H200/MI300X) — số 2023 thổi phồng chi phí 3–4×; đo bằng **$/1M-token**, không $/GPU-hr
- **Đo đúng:** GPU-Util% đánh lừa — dùng MFU/MBU/goodput; đòn bẩy lớn nhất là utilization (10% tải → 10× cost/token)
- **FinOps quick wins:** batch (−50%) × caching (−90%) ≈ **95% off**; fractioning + autoscaling diệt idle; power là nút thắt mới

Tổng kết — Key Takeaways

Những ý chính cần nhớ trước khi sang bài tiếp theo

1. Đo bằng **$/1M-token**, không $/GPU-hr: GB300 đắt/giờ nhưng rẻ nhất/token (35× vs Hopper). Re-baseline mọi TCO về giá 2026.

2. GPU-Util% nói dối — 100% có thể che MFU 20%. Đo **MFU (training) / MBU (decode) / goodput**; purchasing gắn vào break-even utilization ≈ 1−discount%.

3. Discount stack **batch** × **caching** ≈**95% off**; disaggregation 7–30× QPS; fractional GPU + autoscaling diệt idle; FinOps governance qua FOCUS + $/outcome.

Chương 6: Tổng Hợp — MCP/A2A Infrastructure

"Agent gọi agent — MCP server hosting, A2A protocol, agentic routing cho multi-agent systems"

- Hoàn thành Lab 25 + Milestone 2 demo
- Đọc trước: Anthropic MCP specification
- Đọc trước: Google A2A protocol overview

Hỏi & Đáp

Câu hỏi nào về $/1M-token, MFU/MBU, purchasing strategy, discount stack, hay FinOps governance?



Cảm ơn!

AICB-P2T2 · Ngày 25

GPU FinOps & Cost Optimization

`lms.vinuni.edu.vn` · Slide & template trên LMS